ORGANISATION NATIONALE DE LUTTE CONTRE LE FAUX-MONNAYAGE

Détection automatique de faux billets

Construction et comparaison d'algorithmes de machine learning pour classifier automatiquement les billets en euros - Projet 12

Rémy - Data Analyst
Soutenance Projet 12 - OpenClassrooms

SOMMAIRE

Ce que nous allons voir



Le contexte et les données

La mission ONCFM et le jeu de 1500 billets



Analyse exploratoire

Qualité des données, variables discriminantes, ACP



Prétraitement

Imputation, standardisation, séparation train / test



Quatre pistes de modélisation

Régression logistique, KNN, Random Forest, K-means



Comparaison et choix du modèle

Métriques, arbitrages, modèle retenu



L'application fonctionnelle

Notebooks et script de production, démonstration

CONTEXTE

La mission confiée par l'ONCFM



L’ONCFM identifie les contrefaçons de billets en euros. Pour chaque billet scanné, une machine mesure 6 caractéristiques géométriques. L’objectif : construire un algorithme capable de distinguer automatiquement un vrai billet d’un faux, à partir de ces seules mesures.

LIVRABLE 1

Un notebook d’analyse complet et justifié

LIVRABLE 2

Un script de production utilisable en ligne de commande

LIVRABLE 3

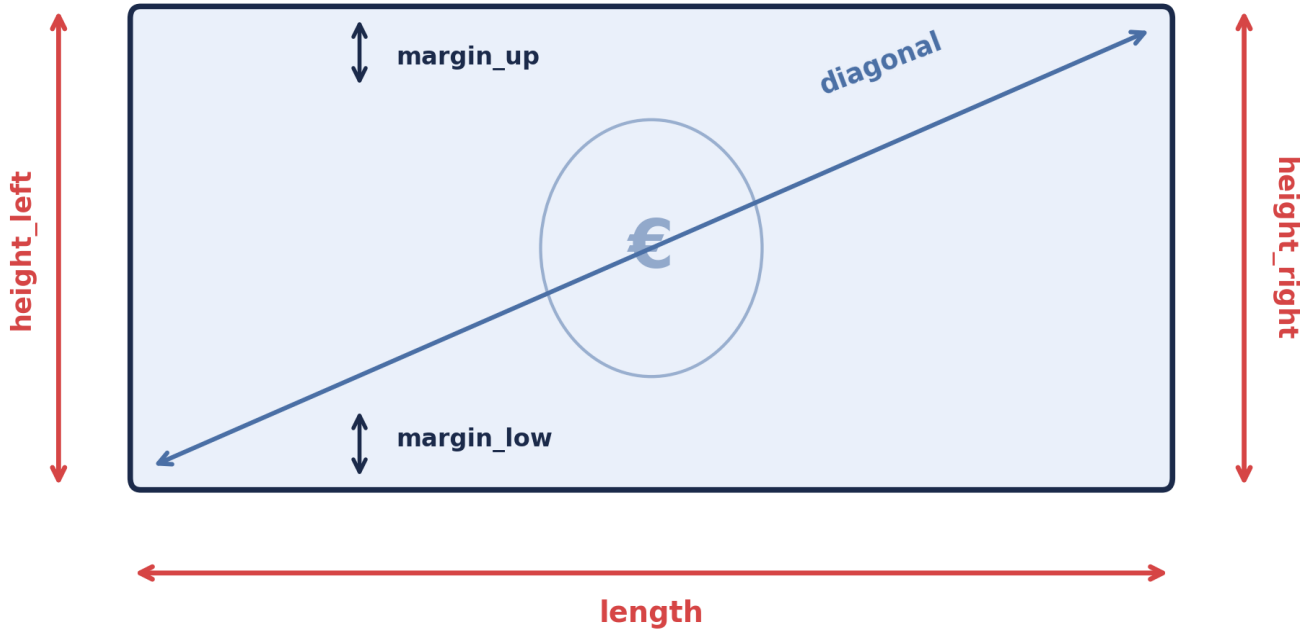
Un support de présentation des résultats et du choix final

1500 billets, 6 mesures géométriques

1500 billets scannés

1000 vrais billets (66,7%)

500 faux billets (33,3%)



Une colonne supplémentaire indique la nature réelle de chaque billet (is_genuine), utilisée pour entraîner et évaluer les modèles.

MÉTHODOLOGIE

Le cheminement du projet



EDA

Explorer et comprendre

Prétraitement

Nettoyer et préparer

Modélisation

4 algorithmes en compétition

Sélection

Comparer et choisir

Production

Déployer et démontrer

Chaque étape s'appuie sur la précédente : les enseignements de l'EDA guident le prétraitement, qui alimente 4 modèles mis en concurrence, dont le meilleur est sélectionné puis livré sous forme d'application utilisable.

ANALYSE EXPLORATOIRE

Qualité et équilibre des données

1500

billets au total

2:1

ratio vrais / faux (déséquilibré)

37

valeurs manquantes (margin_low, 2,5%)

Les valeurs manquantes ne sont pas liées à la nature du billet

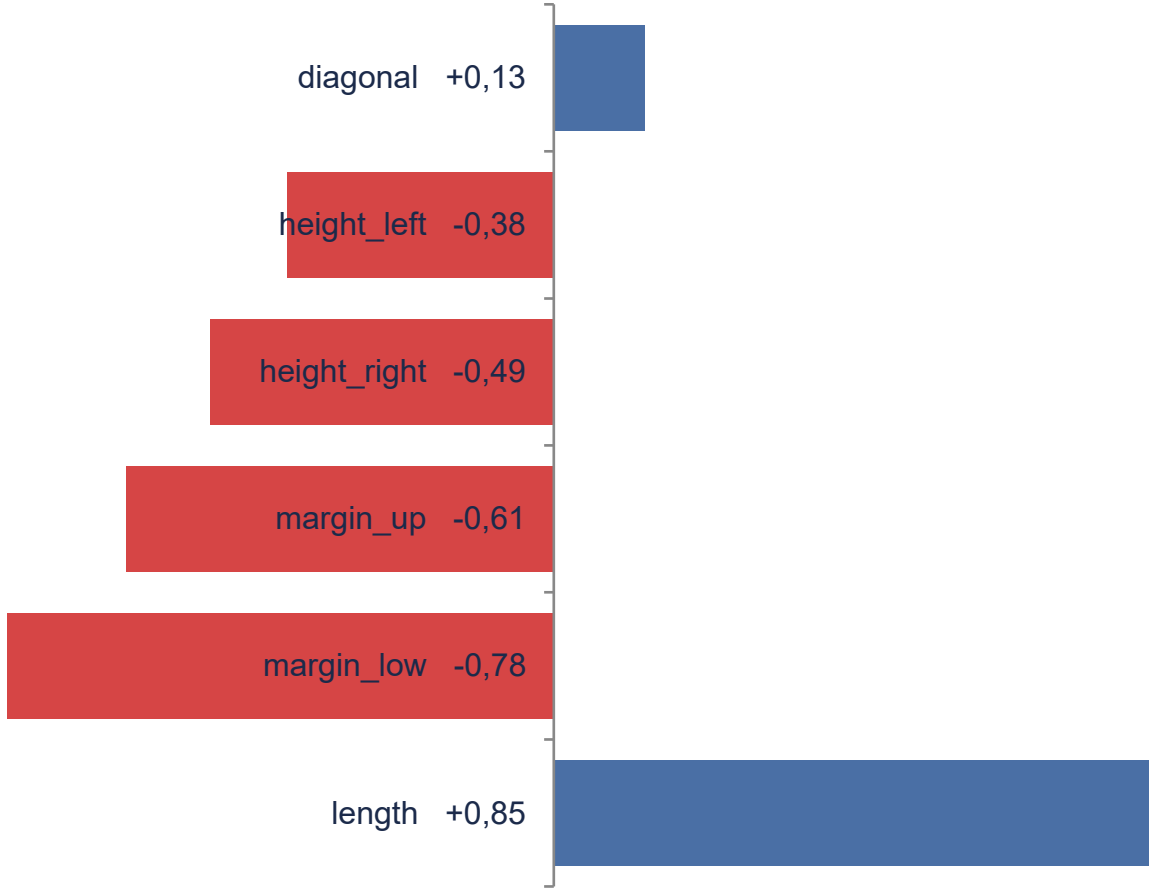
21,6% de faux billets parmi les lignes avec valeur manquante, contre 33,3% dans l'ensemble du jeu de données - aucun biais détecté vis-à-vis de la cible. L'imputation peut donc être menée sereinement (KNNImputer, section prétraitement).



Pourquoi c'est important

Un dataset déséquilibré impose de regarder au-delà de l'accuracy globale.

Quelles variables distinguent vrai et faux ?



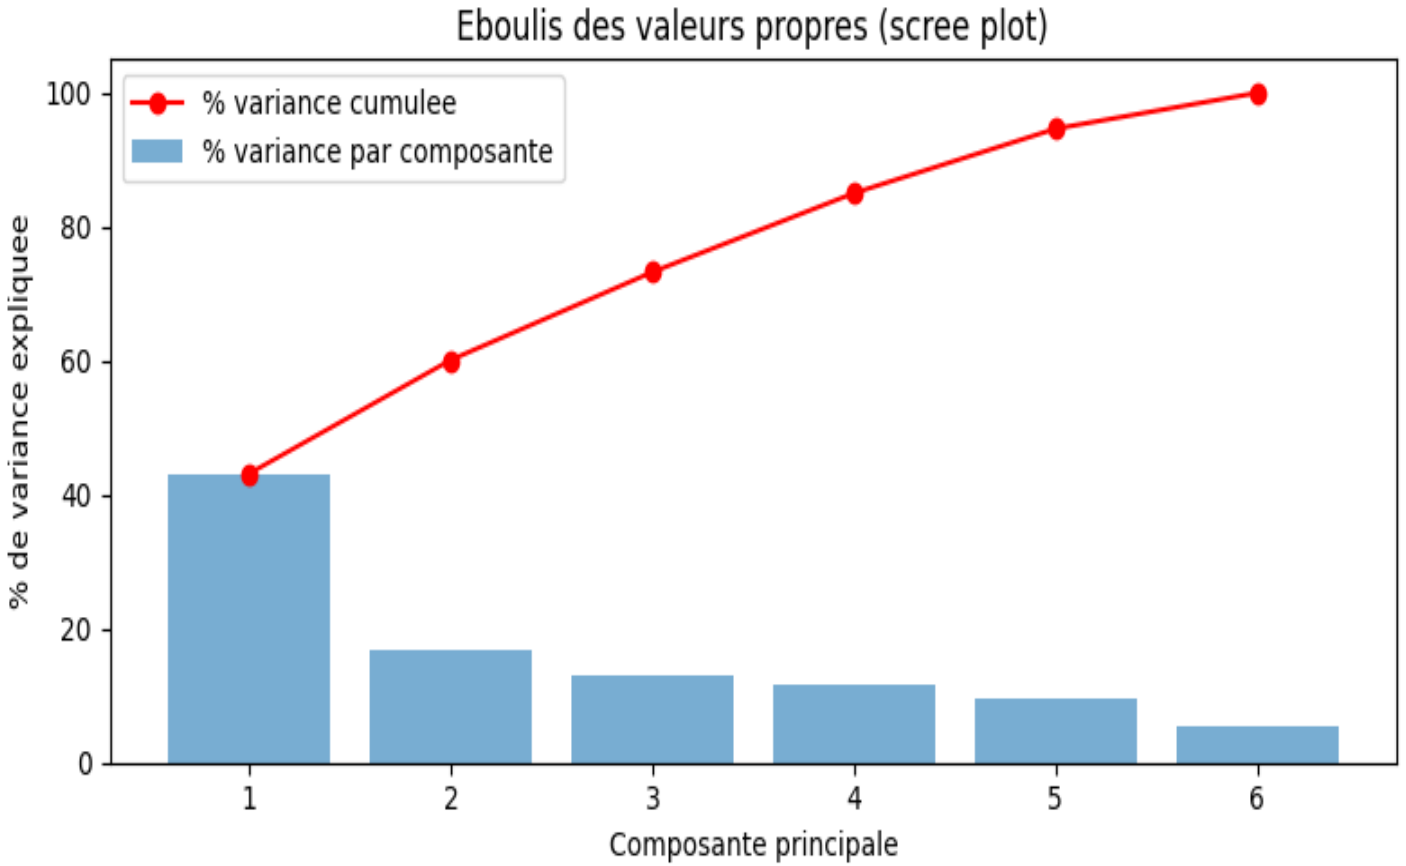
Lecture

• length, margin_low et margin_up sont fortement liées à la nature du billet.

• Les vrais billets sont plus longs et ont des marges plus petites.

• diagonal (+0,13) n'apporte presque rien seule - confirmé plus loin par l'ACP et le Random Forest.

Analyse en composantes principales (ACP)



Ce que confirme l'ACP

60,1%

variance expliquée par
PC1 + PC2

PC1 est dominée par length (+0,53), margin_low (-0,51) et margin_up (-0,44) : c'est quasiment le même axe que celui qui sépare vrai et faux.

PC2 est presque exclusivement portée par diagonal (+0,94) - elle est indépendante de cet axe, ce qui explique son faible pouvoir discriminant.

PRÉTRAITEMENT

Quatre étapes avant la modélisation

1

Séparation X / y

Variables géométriques (X) et étiquette vrai/faux (y).

2

Split train / test

80% / 20%, stratifié, effectué avant toute transformation pour éviter la fuite de données.

3

Imputation (KNNImputer)

Les 37 valeurs manquantes de margin_low sont estimées à partir des billets les plus proches. Calibré sur le train uniquement.

4

Standardisation

Moyenne 0, écart-type 1 sur chaque variable - indispensable pour la régression logistique, le KNN et le K-means.

MODÉLISATION

Quatre pistes mises en compétition



SUPERVISÉ

Régression logistique

Combinaison linéaire des variables, transformée en probabilité. Directement interprétable via ses coefficients.



SUPERVISÉ

KNN

Classe un billet selon la majorité parmi ses K voisins les plus proches. K=11 retenu après test de plusieurs valeurs.



SUPERVISÉ

Random Forest

200 arbres de décision entraînés sur des sous-échantillons aléatoires, dont le vote majoritaire décide.

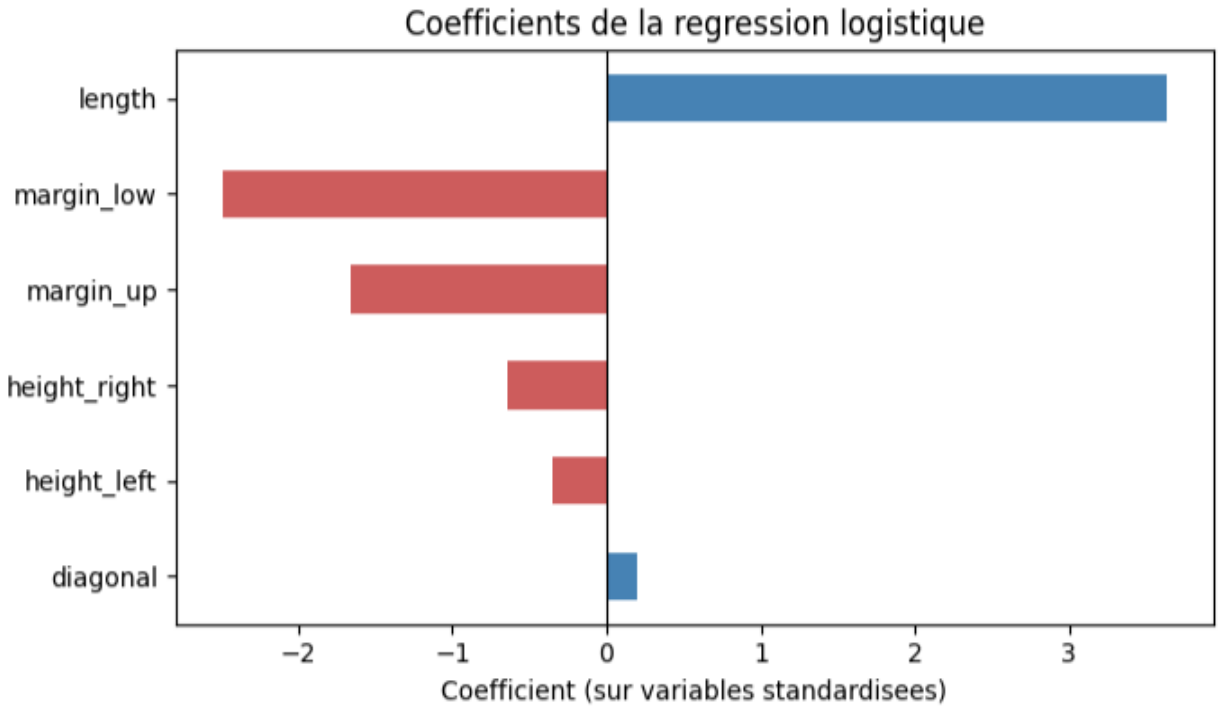


NON SUPERVISÉ

K-means

Regroupe les billets en 2 clusters sans jamais voir les étiquettes ; les clusters sont ensuite associés à vrai/faux.

Régression logistique

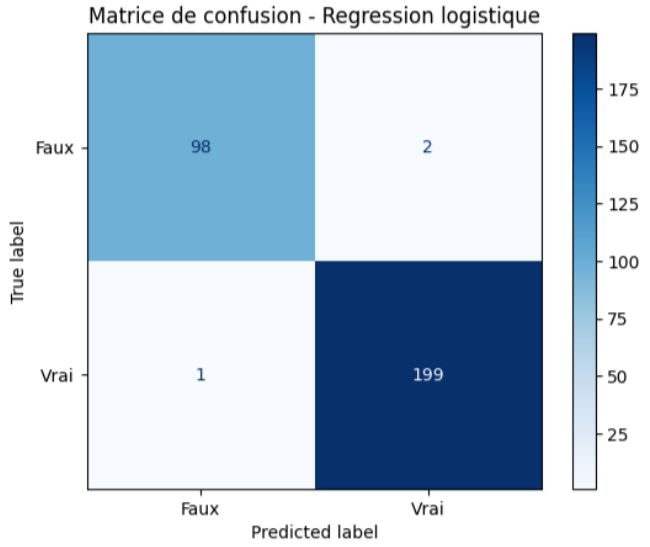


99%

Accuracy

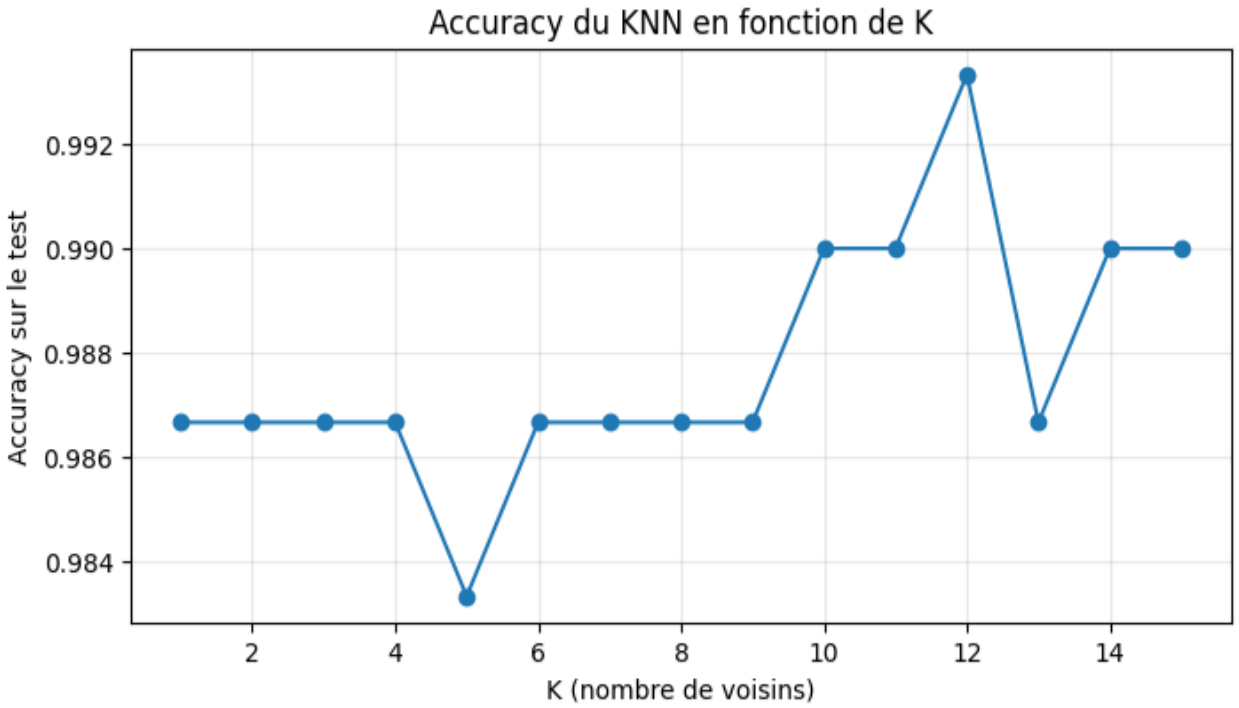
98%

Recall (Faux)



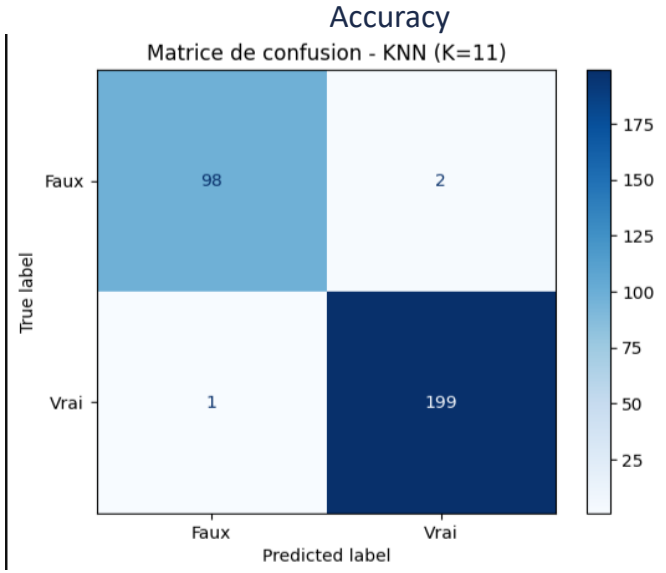
length et margin_low dominent la décision, diagonal est quasi neutre : le même classement que celui trouvé en EDA et en ACP.

KNN (K plus proches voisins)



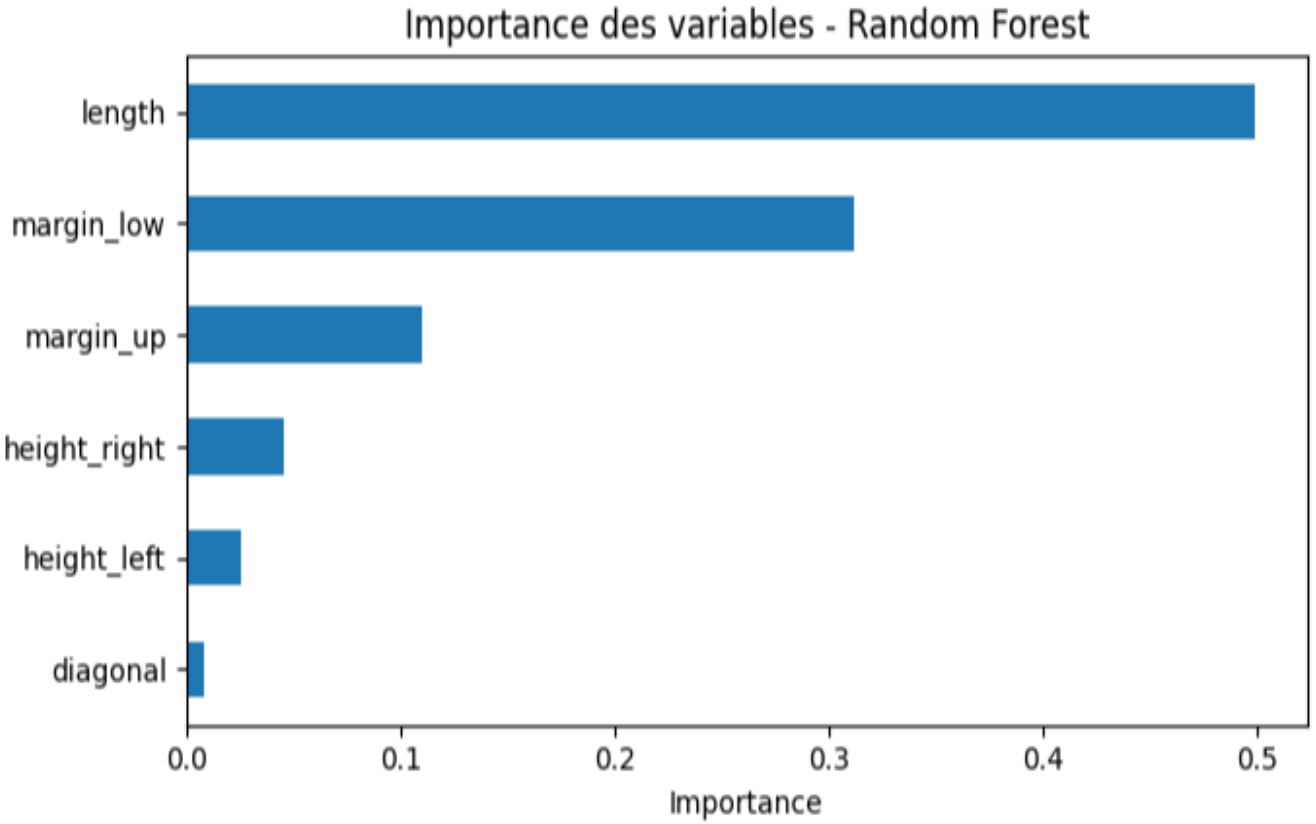
99%

Accuracy



Pour une classification binaire, un K pair risque une égalité de vote. K=11 (score quasi identique au meilleur, K=12) est donc préféré pour sa robustesse.

Random Forest

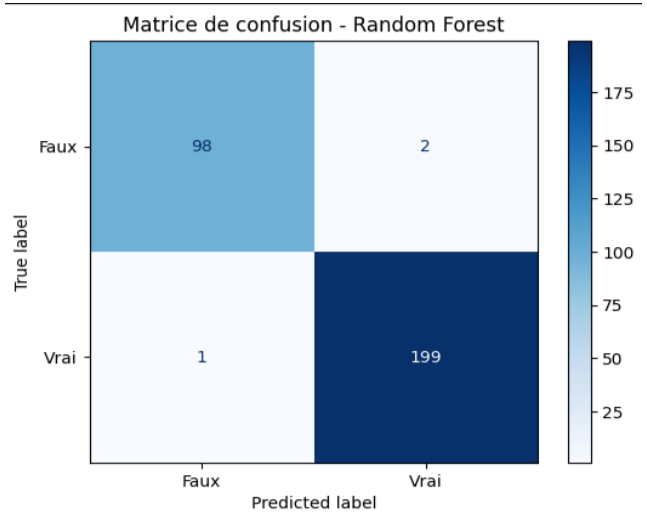


99%

Accuracy

98%

Recall (Faux)

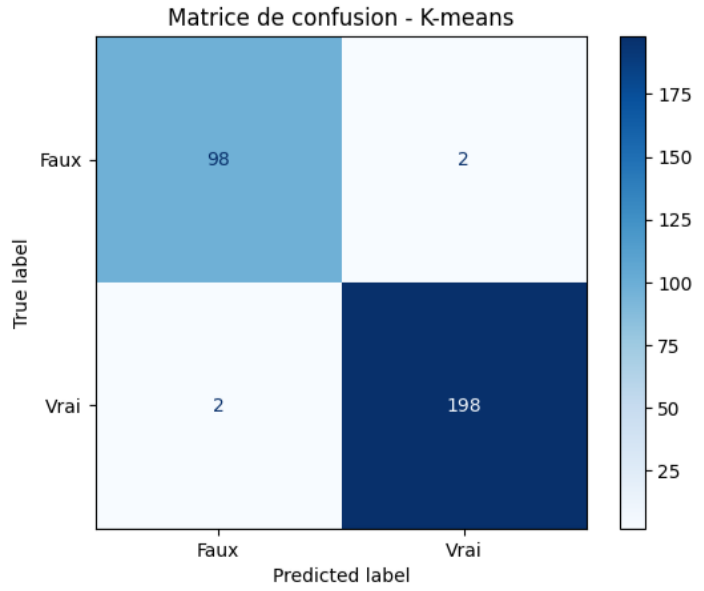


length et margin_low portent à elles seules 81% de la décision. Même performance que la régression logistique, avec 200 arbres au lieu d'une formule.

K-means (non supervisé)

Méthode

1. Entraîner K-means (K=2) sur les données standardisées, sans utiliser les étiquettes
2. Associer chaque cluster à vrai/faux selon sa composition majoritaire
3. Prédire sur le test en remappant les clusters, puis évaluer



98,67%

Accuracy

0,345

Silhouette score

Sans jamais voir les étiquettes, le K-means retrouve presque parfaitement la vérité terrain - preuve que les deux classes sont naturellement bien séparées dans les données.

SÉLECTION

Comparaison des 4 modèles

Modèle	Accuracy	Precision (Faux)	Recall (Faux)	F1 (Faux)
Régression logistique	0,9900	0,9899	0,98	0,9849
KNN (K=11)	0,9900	0,9899	0,98	0,9849
Random Forest	0,9900	0,9899	0,98	0,9849
K-means	0,9867	0,9800	0,98	0,9800

Un constat clé : les 3 modèles supervisés se trompent sur les 3 mêmes billets

Régression logistique, KNN et Random Forest partagent exactement les 3 mêmes erreurs sur le jeu de test. Ces cas proviennent probablement de billets aux mesures proches de la frontière vrai/faux, plutôt que d'une faiblesse propre à un algorithme.

Le recall (Faux) est identique pour les 4 modèles : 98%

La différence se joue sur l'accuracy et la precision - critères secondaires ici.

MODÈLE RETENU

La régression logistique

- **Performance strictement identique** aux 2 autres meilleurs modèles : mêmes 3 erreurs, même recall (98%).
- **Un ordre de grandeur plus simple** une seule formule linéaire, contre 200 arbres de décision pour le Random Forest.
- **Interprétabilité directe** les coefficients expliquent en une phrase pourquoi un billet est jugé faux.
- **Léger et rapide** à entraîner comme à utiliser en production, sans compromis de performance.

Le Random Forest reste un excellent candidat de secours, plus robuste face à d'éventuelles relations non linéaires futures.

APPLICATION FONCTIONNELLE

De l'analyse à la production



Notebook d’analyse

EDA, prétraitement,
4 modèles, sélection



Modèle sauvegardé

Pipeline complet
(.joblib)



Notebook de démo

Chargement +
inférence



Script de production

predict_billets.py
en ligne de commande

Le script accepte en entrée soit un fichier CSV (plusieurs billets), soit les mesures d’un billet unique en ligne de commande. Il renvoie une prédiction (vrai/faux) et sa probabilité associée - y compris si une valeur est manquante, grâce à l’imputation intégrée au pipeline.

APPLICATION FONCTIONNELLE

Démonstration en direct

2.3) Demonstration - prediction d'un billet unique

```
!python predict_billets.py --diagonal 171.8 --height_left 104.0 --height_right 104.2 --margin_low 4.3 --margin_up 3.1 --length 113.1

Prediction : VRAI
Probabilite vrai billet : 98.59%
Probabilite faux billet : 1.41%
```

Prêt pour un test en direct avec un fichier au format billets_production.csv - le script fonctionne identiquement, ligne par ligne, sur un jeu de plusieurs billets.

CONCLUSION

Bilan et perspectives

Ce qui a été livré

- Une analyse complète et justifiée (EDA, ACP, prétraitement)
- 4 algorithmes testés, comparés et interprétés
- Un modèle final choisi et argumenté (99% accuracy, 98% recall)
- Une application fonctionnelle (2 notebooks + script)

Limites et perspectives

- 3 billets aux mesures ambiguës restent mal classifiés par tous les modèles
- Échantillon de 1500 billets - à confirmer sur un volume de production plus large
- Seuil de décision ajustable selon le coût métier réel (faux positif vs faux négatif)
- Réentraînement périodique recommandé si de nouvelles techniques de contrefaçon émergent



Merci de votre attention

Des questions ?